



Institut National et Supérieur de l'Informatique

Mention Informatique – Parcours Intelligence Artificielle et
Data Science

Examen Machine Learning

Présenté par : RASOLOFOMANANA Aina Herilanja

Matricule : 126/LA/25-26

Profe : Dr.RAMASONDRANO Andriamanjaka

20 mai 2026

Table des matières

1	Introduction	2
1.1	Contexte clinique	2
1.2	Objectifs du projet	2
1.3	Organisation du rapport	2
2	Dataset et Préparation des Données	3
2.1	Description du dataset	3
2.2	Nettoyage des données	3
3	Analyse Exploratoire des Données (EDA)	4
3.1	Distributions univariées	4
3.2	Variables catégorielles vs cible	6
3.3	Matrice de corrélation	7
3.4	Analyse par sexe	8
4	Modèles de Machine Learning et Entraînement	9
4.1	Pipeline de préparation	9
4.2	Modèles entraînés	10
4.2.1	Régression Logistique (LR)	10
4.2.2	Forêt Aléatoire (RF)	10
4.2.3	K-Plus Proches Voisins (KNN)	10
4.3	Validation croisée	10
5	Évaluation et Comparaison des Performances	11
5.1	Métriques utilisées	11
5.2	Résultats comparatifs	11

1 Introduction

1.1 Contexte clinique

Les maladies cardiovasculaires constituent l'une des principales causes de mortalité dans le monde. Selon l'Organisation Mondiale de la Santé, elles sont responsables de près de 18 millions de décès par an, soit environ 31 % de la mortalité mondiale. Un diagnostic précoce et fiable est donc crucial pour permettre une prise en charge adaptée.

Le recours à des techniques d'apprentissage automatique (*machine learning*) pour assister le diagnostic médical représente un domaine de recherche actif. L'objectif est de modéliser la relation entre des caractéristiques cliniques mesurables — pression artérielle, cholestérol, électrocardiogramme, etc. — et la présence d'une pathologie cardiaque.

1.2 Objectifs du projet

Ce projet vise à :

1. Charger, nettoyer et explorer le dataset *Heart Disease UCI* ;
2. Analyser les distributions et corrélations des variables cliniques ;
3. Entraîner et évaluer trois algorithmes de classification supervisée ;
4. Comparer leurs performances sur plusieurs métriques ;
5. Identifier les variables les plus prédictives ;
6. Proposer des pistes d'amélioration pour la mise en production.

1.3 Organisation du rapport

Structure du rapport

Section 2 — Description du dataset et préparation des données

Section 3 — Analyse exploratoire (EDA)

Section 4 — Modèles de machine learning et entraînement

Section 5 — Évaluation et comparaison des performances

Section 6 — Interprétation des résultats

Section 7 — Améliorations proposées

Section 8 — Exportation et déploiement

Section 9 — Conclusion

2 Dataset et Préparation des Données

2.1 Description du dataset

Le dataset utilisé est le **Heart Disease UCI** (Cleveland Clinic Foundation), disponible sur le UCI Machine Learning Repository. Il contient des données médicales collectées sur **303 patients**.

TABLE 1 – Description des 14 variables du dataset

Variable	Type	Description
<code>age</code>	Continue	Âge du patient (en années)
<code>sex</code>	Binaire	Sexe (0 = Femme, 1 = Homme)
<code>cp</code>	Catégorielle	Type de douleur thoracique (0–3)
<code>trestbps</code>	Continue	Pression artérielle au repos (mm Hg)
<code>chol</code>	Continue	Cholestérol sérique (mg/dl)
<code>fbs</code>	Binaire	Glycémie à jeun > 120 mg/dl (0/1)
<code>restecg</code>	Catégorielle	Résultats ECG au repos (0–2)
<code>thalach</code>	Continue	Fréquence cardiaque maximale atteinte
<code>exang</code>	Binaire	Angine induite par l'exercice (0/1)
<code>oldpeak</code>	Continue	Dépression du segment ST
<code>slope</code>	Catégorielle	Pente du segment ST (0–2)
<code>ca</code>	Ordinale	Nombre de vaisseaux colorés (0–4)
<code>thal</code>	Catégorielle	Thalassémie (0, 1, 2, 3)
<code>target</code>	Binaire	Cible : 0 = Sain, 1 = Maladie cardiaque

2.2 Nettoyage des données

Le pipeline de nettoyage appliqué comprend les étapes suivantes :

1. **Valeurs manquantes** : Vérification systématique — aucune valeur manquante détectée dans ce dataset.
2. **Doublons** : Identification et suppression des lignes dupliquées afin d'éviter tout biais dans l'entraînement.
3. **Cholestérol nul** : Les valeurs `chol` = 0 sont physiologiquement impossibles et correspondent à des données manquantes encodées. Elles ont été remplacées par la **médiane** du cholestérol.
4. **Pression artérielle nulle** : Même traitement pour `trestbps` = 0.

```
=====
RAPPORT DE NETTOYAGE
=====

1. Valeurs manquantes : 0 au total

2. Doublons : 1
   → 1 ligne(s) supprimée(s). Nouveau shape : (302, 14)

3. Cholestérol = 0 : 0 cas

4. Pression artérielle = 0 : 0 cas

5. Distribution de la cible :
   Classe 1 (Maladie cardiaque) : 164 (54.3%)
   Classe 0 (Sain) : 138 (45.7%)

Dataset propre : 302 lignes × 14 colonnes
```

FIGURE 1 – Rapport de nettoyage

Distribution de la variable cible

- Classe 0 — Sain : **138 patients** (45,7 %)
- Classe 1 — Maladie cardiaque : **164 patients** (54,3 %)

Le dataset est pratiquement **équilibré**, ce qui rend la métrique *Accuracy* fiable et ne nécessite pas de rééchantillonnage (SMOTE).

3 Analyse Exploratoire des Données (EDA)

3.1 Distributions univariées

Distribution de l'âge. Les patients sont âgés de 29 à 77 ans, avec une médiane autour de 55 ans. Les patients malades sont légèrement plus jeunes en moyenne, ce qui peut sembler contre-intuitif mais s'explique par un biais de sélection de l'échantillon clinique.





FIGURE 2 – Distributions des variables continues par classe cible

Fréquence cardiaque maximale ([thalach](#)). Les patients sains présentent une fréquence cardiaque maximale plus élevée. Une [thalach](#) élevée est généralement signe d'un système cardiovasculaire en meilleure santé.

FIGURE 3 – Distribution de la fréquence cardiaque maximale ([thalach](#)) par classe cible

Dépression du segment ST (`oldpeak`). Les patients malades affichent un `oldpeak` plus élevé, ce qui est cohérent avec la physiopathologie de l'ischémie myocardique.




FIGURE 4 – Distribution de la dépression du segment ST (`oldpeak`) par classe cible

3.2 Variables catégorielles vs cible




FIGURE 5 – Distribution des variables catégorielles par classe cible

TABLE 2 – Interprétation des variables catégorielles les plus discriminantes

Variable	Observation
<code>cp</code> (douleur thoracique)	La douleur asymptomatique (type 0) est fortement associée aux patients malades — paradoxe clinique important
<code>thal</code> (thalassémie)	Le type 2 (flux normal) est associé à l'absence de maladie ; les types 1 et 3 (défects) au groupe malade
<code>slope</code> (pente ST)	Une pente descendante est plus fréquente chez les malades
<code>ca</code> (vaisseaux colorés)	Plus le nombre de vaisseaux colorés est élevé, plus le risque de maladie augmente

3.3 Matrice de corrélation

L'analyse de la matrice de corrélation de Pearson révèle les relations suivantes avec la variable cible `target` :

TABLE 3 – Corrélations avec la cible (valeur absolue, triées par importance)

Feature	Corrélation	Direction
<code>thal</code>	−0,34	Négatif
<code>cp</code>	+0,43	Positif
<code>ca</code>	−0,41	Négatif
<code>thalach</code>	+0,42	Positif
<code>oldpeak</code>	−0,43	Négatif
<code>exang</code>	−0,44	Négatif
<code>slope</code>	+0,34	Positif
<code>sex</code>	−0,28	Négatif
<code>age</code>	−0,23	Négatif




FIGURE 6 – Matrice de corrélation de Pearson entre les variables continues et la cible

Observations clés :

- La corrélation maximale est modérée ($\leq 0,43$) : aucune variable n'est à elle seule suffisante pour le diagnostic.
- La quasi-absence de corrélation de **fbs** et **restecg** avec la cible suggère leur faible pouvoir prédictif individuel.
- Les intercorrélations entre variables explicatives restent raisonnables, limitant le risque de multicolinéarité pour la Régression Logistique.

3.4 Analyse par sexe

Une disparité notable est observée : les **femmes** présentent un taux de maladie cardiaque plus élevé dans cet échantillon que les hommes. Ce résultat, contre-intuitif par rapport aux statistiques épidémiologiques générales, reflète le biais de sélection propre à ce dataset clinique.




FIGURE 7 – Distribution de la variable cible par sexe

4 Modèles de Machine Learning et Entraînement

4.1 Pipeline de préparation

Avant l'entraînement, les données sont séparées en un ensemble d'entraînement et un ensemble de test selon un ratio **80/20** avec stratification sur la variable cible.

Listing 1 – Split stratifié 80/20

```
X = df.drop('target', axis=1)
y = df['target']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)

scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)
```

La **Standardisation** (`StandardScaler`) est appliquée pour les modèles sensibles à l'échelle des features (Régression Logistique et KNN), mais pas pour la Forêt Aléatoire qui est invariante à l'échelle.

4.2 Modèles entraînés

4.2.1 Régression Logistique (LR)

Régression Logistique

Paramètres : solver = LBFGS · C = 1,0 · max_iter = 1000

Principe : Modèle linéaire qui estime la probabilité $P(Y = 1|X)$ via la fonction sigmoïde :

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}}$$

Avantages : Interprétabilité, rapidité, baselines solide

Limites : Suppose une frontière de décision linéaire

4.2.2 Forêt Aléatoire (RF)

Random Forest

Paramètres : n_estimators = 200 · max_depth = 10 · critère = Gini

Principe : Ensemble de 200 arbres de décision entraînés sur des sous-échantillons bootstrap. La prédiction finale est la classe majoritaire (vote).

Avantages : Robustesse au bruit, capture des non-linéarités, fournit les importances de features

Limites : Moins interprétable qu'un arbre unique, plus coûteux en mémoire

4.2.3 K-Plus Proches Voisins (KNN)

K-Nearest Neighbors

Paramètres : K = 7 · distance = Euclidienne

Principe : Classifie un point selon la majorité de ses K plus proches voisins dans l'espace des features standardisées.

Avantages : Non-paramétrique, adaptatif

Limites : Sensible au choix de K, coûteux à l'inférence sur grands datasets, sensible aux outliers

4.3 Validation croisée

Une **validation croisée stratifiée à 5 plis** (StratifiedKFold) est appliquée sur l'ensemble d'entraînement afin d'estimer la capacité de généralisation de chaque modèle et détecter un éventuel surapprentissage.

$$CV_\mu = \frac{1}{5} \sum_{k=1}^5 \text{Score}_k \quad CV_\sigma = \sqrt{\frac{1}{5} \sum_{k=1}^5 (\text{Score}_k - CV_\mu)^2}$$

5 Évaluation et Comparaison des Performances

5.1 Métriques utilisées

Pour une tâche de classification binaire médicale, plusieurs métriques sont nécessaires :

TABLE 4 – Définition des métriques d’évaluation

Métrique	Formule et interprétation
Accuracy	$\frac{TP+TN}{TP+TN+FP+FN}$ — proportion globale de bonnes prédictions
Précision	$\frac{TP}{TP+FP}$ — parmi les cas prédits malades, combien le sont vraiment
Rappel	$\frac{TP}{TP+FN}$ — parmi les vrais malades, combien sont correctement détectés
F1-Score	$2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$ — compromis précision/rappel
AUC-ROC	Aire sous la courbe ROC — capacité discriminante globale

Note médicale : Dans un contexte de dépistage cardiaque, le **rappel** (sensibilité) est particulièrement important : manquer un vrai malade (faux négatif) est plus grave que signaler un faux positif.

5.2 Résultats comparatifs

TABLE 5 – Tableau comparatif des performances sur l’ensemble de test

Modèle	Acc.	Prec.	Rappel	F1	AUC	CV Moy.	CV Std
Logistic Reg.	78,69%	76,32%	87,88%	81,69%	86,47%	81,34%	±6,53%
Random Forest	80,33%	75,61%	93,94%	83,78%	88,64%	83,41%	±7,07%
KNN	81,97%	78,95%	90,91%	84,51%	89,12%	80,09%	±2,73%

Meilleur modèle : KNN ★

- **F1-Score** : 84,51 % (meilleur compromis précision/rappel)
- **AUC-ROC** : 89,12 % (excellente capacité discriminante)
- **Accuracy** : 81,97 % sur l’ensemble de test
- **CV 5-fold** : 80,09 % ± 2,73 % (bonne généralisation)