



Institut National et Supérieur de l'Informatique

Mention Informatique – Parcours Intelligence Artificielle et
Data Science

Examen Machine Learning

Présenté par : RASOLOFOMANANA Aina Herilanja

Matricule : 126/LA/25-26

Profe : Dr.RAMASONDRANO Andriamanjaka

20 mai 2026

Table des matières

1	Introduction	2
1.1	Contexte clinique	2
1.2	Objectifs du projet	2
1.3	Organisation du rapport	2
2	Dataset et Préparation des Données	3
2.1	Description du dataset	3
2.2	Nettoyage des données	3
3	Analyse Exploratoire des Données (EDA)	4
3.1	Distributions univariées	4
3.2	Variables catégorielles vs cible	4

1 Introduction

1.1 Contexte clinique

Les maladies cardiovasculaires constituent l'une des principales causes de mortalité dans le monde. Selon l'Organisation Mondiale de la Santé, elles sont responsables de près de 18 millions de décès par an, soit environ 31 % de la mortalité mondiale. Un diagnostic précoce et fiable est donc crucial pour permettre une prise en charge adaptée.

Le recours à des techniques d'apprentissage automatique (*machine learning*) pour assister le diagnostic médical représente un domaine de recherche actif. L'objectif est de modéliser la relation entre des caractéristiques cliniques mesurables — pression artérielle, cholestérol, électrocardiogramme, etc. — et la présence d'une pathologie cardiaque.

1.2 Objectifs du projet

Ce projet vise à :

1. Charger, nettoyer et explorer le dataset *Heart Disease UCI* ;
2. Analyser les distributions et corrélations des variables cliniques ;
3. Entraîner et évaluer trois algorithmes de classification supervisée ;
4. Comparer leurs performances sur plusieurs métriques ;
5. Identifier les variables les plus prédictives ;
6. Proposer des pistes d'amélioration pour la mise en production.

1.3 Organisation du rapport

Structure du rapport

Section 2 — Description du dataset et préparation des données

Section 3 — Analyse exploratoire (EDA)

Section 4 — Modèles de machine learning et entraînement

Section 5 — Évaluation et comparaison des performances

Section 6 — Interprétation des résultats

Section 7 — Améliorations proposées

Section 8 — Exportation et déploiement

Section 9 — Conclusion

2 Dataset et Préparation des Données

2.1 Description du dataset

Le dataset utilisé est le **Heart Disease UCI** (Cleveland Clinic Foundation), disponible sur le UCI Machine Learning Repository. Il contient des données médicales collectées sur **303 patients**.

TABLE 1 – Description des 14 variables du dataset

Variable	Type	Description
<code>age</code>	Continue	Âge du patient (en années)
<code>sex</code>	Binaire	Sexe (0 = Femme, 1 = Homme)
<code>cp</code>	Catégorielle	Type de douleur thoracique (0–3)
<code>trestbps</code>	Continue	Pression artérielle au repos (mm Hg)
<code>chol</code>	Continue	Cholestérol sérique (mg/dl)
<code>fbs</code>	Binaire	Glycémie à jeun > 120 mg/dl (0/1)
<code>restecg</code>	Catégorielle	Résultats ECG au repos (0–2)
<code>thalach</code>	Continue	Fréquence cardiaque maximale atteinte
<code>exang</code>	Binaire	Angine induite par l'exercice (0/1)
<code>oldpeak</code>	Continue	Dépression du segment ST
<code>slope</code>	Catégorielle	Pente du segment ST (0–2)
<code>ca</code>	Ordinale	Nombre de vaisseaux colorés (0–4)
<code>thal</code>	Catégorielle	Thalassémie (0, 1, 2, 3)
<code>target</code>	Binaire	Cible : 0 = Sain, 1 = Maladie cardiaque

2.2 Nettoyage des données

Le pipeline de nettoyage appliqué comprend les étapes suivantes :

1. **Valeurs manquantes** : Vérification systématique — aucune valeur manquante détectée dans ce dataset.
2. **Doublons** : Identification et suppression des lignes dupliquées afin d'éviter tout biais dans l'entraînement.
3. **Cholestérol nul** : Les valeurs `chol` = 0 sont physiologiquement impossibles et correspondent à des données manquantes encodées. Elles ont été remplacées par la **médiane** du cholestérol.
4. **Pression artérielle nulle** : Même traitement pour `trestbps` = 0.

Distribution de la variable cible

- Classe 0 — Sain : **138 patients** (45,5 %)
- Classe 1 — Maladie cardiaque : **165 patients** (54,5 %)

Le dataset est pratiquement **équilibré**, ce qui rend la métrique *Accuracy* fiable et ne nécessite pas de rééchantillonnage (SMOTE).

3 Analyse Exploratoire des Données (EDA)

3.1 Distributions univariées

Distribution de l'âge. Les patients sont âgés de 29 à 77 ans, avec une médiane autour de 55 ans. Les patients malades sont légèrement plus jeunes en moyenne, ce qui peut sembler contre-intuitif mais s'explique par un biais de sélection de l'échantillon clinique.

Fréquence cardiaque maximale ([thalach](#)). Les patients sains présentent une fréquence cardiaque maximale plus élevée. Une [thalach](#) élevée est généralement signe d'un système cardiovasculaire en meilleure santé.

Dépression du segment ST ([oldpeak](#)). Les patients malades affichent un [oldpeak](#) plus élevé, ce qui est cohérent avec la physiopathologie de l'ischémie myocardique.

3.2 Variables catégorielles vs cible

TABLE 2 – Interprétation des variables catégorielles les plus discriminantes

Variable	Observation
cp (douleur thoracique)	La douleur asymptomatique (type 0) est fortement associée aux patients malades — paradoxe clinique important
thal (thalassémie)	Le type 2 (flux normal) est associé à l'absence de maladie ; les types 1 et 3 (défects) au groupe malade
slope (pente ST)	Une pente descendante est plus fréquente chez les malades
ca (vaisseaux colorés)	Plus le nombre de vaisseaux colorés est élevé, plus le risque de maladie augmente